

Modelos Preditivos para Estimação de Status de Empréstimos via Machine Learning: Uma Abordagem Baseada na Metodologia CRISP-DM

Mário Diego Rocha Valente¹, Gabriel Baia da Silva¹, Jefferson Magalhães de Moraes²

¹Graduando em Sistemas de Informação - Universidade Federal do Pará (UFPA)
Rua Augusto Corrêa 01 – Guamá – Belém – PA – Brasil

²Professor Dr., Faculdade de Computação - Universidade Federal do Pará (UFPA)
Av. Augusto Corrêa 01 – Guamá – Belém – PA – Brasil

diego.vatente@gmail.com; gabrielkadran@hotmail.com; jmorais@ufpa.br

Resumo. O objetivo deste trabalho foi aplicar modelos preditivos de aprendizado de máquina para classificação de status de empréstimo, estruturada sob a metodologia CRISP-DM. O conjunto de dados, obtido do Kaggle, contém informações de empréstimos imobiliários. O dataset foi utilizado para realizar a comparação entre modelos de aprendizado de máquina e determinar dentre estes qual o mais adequado para a decisão sobre a liberação de crédito imobiliário. A amostra foi dividida em dados de treino (80%) e teste (20%), com aplicação de padronização escalar rigorosa (Z-score) e otimização de hiperparâmetros, que foi realizada por Grid Search, associada à validação cruzada 10-fold. Nesta comparação, por meio da Curva ROC, o Random Forest foi identificado como o modelo mais adequado para a aplicação, atingindo uma AUC de 82,6%, contra 80,6% do Voting e 72,7% da Regressão Logística.

Abstract. The objective of this study was to apply predictive machine learning models for loan status classification, structured under the CRISP-DM methodology. The dataset, obtained from Kaggle, contains information on real estate loans. It was used to compare machine learning models and determine the most suitable one for decision-making regarding real estate credit approval. The sample was split into training (80%) and testing (20%) sets, followed by the application of rigorous standard scaling (Z-score) and hyperparameter optimization, which was performed by Grid Search associated with 10-fold cross-validation. Through this comparison using the ROC Curve, Random Forest was identified as the most appropriate model for this application, achieving an AUC of 82.6%, compared to 80.6% for the Voting classifier and 72.7% for Logistic Regression.

1. Introdução

A análise de solicitações de crédito imobiliário envolve decisões que devem considerar simultaneamente eficiência operacional e capacidade de discriminação entre solicitações aprovadas e rejeitadas. Nesse contexto, modelos preditivos podem apoiar a triagem de propostas e contribuir para decisões mais consistentes a partir das características cadastrais, financeiras e imobiliárias dos solicitantes [1].

Este estudo utiliza o conjunto de dados `loan_data.csv`, obtido no **Kaggle**, referente a dados de clientes de empréstimo bancário. A variável binária `Loan_Status`,

correspondente ao status de aprovação do empréstimo sendo 0 reprovado ou 1 aprovado, é o nosso alvo (*target*) de análise. O desenvolvimento foi estruturado segundo a metodologia *Cross Industry Standard Process for Data Mining* (CRISP-DM), contemplando o entendimento do negócio e dos dados, a preparação da base, a modelagem e a avaliação dos resultados [2].

Foram comparados oito classificadores: Regressão Logística(*baseline*), Árvore de Decisão, k-Nearest Neighbors, Naive Bayes Gaussiano, Support Vector Machine, Multilayer Perceptron, Random Forest e Voting Classifier. O objetivo é identificar o modelo com melhor desempenho na classificação do status dos empréstimos e analisar sua capacidade discriminatória por meio de métricas de avaliação aplicadas ao conjunto de teste.

2. Materiais e Métodos

O desenvolvimento deste estudo seguiu as seis etapas do framework CRISP-DM, garantindo uma abordagem estruturada.

2.1. Entendimento do Negócio

Nesta fase, buscou-se alinhar os objetivos técnicos com as necessidades financeiras [2]. O foco é automatizar a triagem de crédito imobiliário para reduzir a inadimplência e aumentar a eficiência operacional da instituição financeira.

2.2. Entendimento dos Dados

O conjunto de dados `loan_data.csv`, obtido no Kaggle, possui 381 registros e 13 colunas. As variáveis descrevem características sociodemográficas (Gender, Married, Dependents, Education e Self_Employed), informações financeiras (ApplicantIncome, CoapplicantIncome, LoanAmount e Loan_Amount_Term), histórico de crédito (Credit_History) e área do imóvel (Property_Area). A coluna `Loan_ID` foi preservada para associar cada previsão à solicitação correspondente, mas não foi utilizada como atributo preditor. A variável-alvo `Loan_Status` representa o status da solicitação, originalmente indicado por Y (aprovado) e N (rejeitado).

2.3. Preparação dos Dados

A preparação da base incluiu a verificação dos valores ausentes, o ajuste dos tipos de dados e a codificação das variáveis categóricas. Os valores faltantes em Gender, Dependents e Self_Employed foram substituídos pelas respectivas modas, enquanto os valores ausentes em Loan_Amount_Term e Credit_History foram preenchidos pelas medianas. As variáveis numéricas foram convertidas para os tipos adequados, incluindo ApplicantIncome, Loan_Amount_Term e Credit_History. Em seguida, as variáveis categóricas e a variável-alvo foram transformadas em valores numéricos por meio do *Label Encoding*, sendo Y e N convertidos para as classes 1 e 0, respectivamente. Ao final, a matriz de atributos foi separada da variável-alvo e utilizada no treinamento e na avaliação dos classificadores.

2.4. Modelagem

Foram avaliados oito métodos de classificação: **Regressão Logística**, **Árvore de Decisão**, **k-Nearest Neighbors (kNN)**, **Naive Bayes Gaussiano**, **Support Vector Machine (SVM)**, **Multilayer Perceptron (MLP)**, **Random Forest** e **Voting Classifier**. O

conjunto contempla modelos lineares, probabilísticos, baseados em instâncias, árvores de decisão e redes neurais. Entre os métodos de *ensemble*, destaca-se o **Random Forest**, formado pela combinação de múltiplas árvores, e o **Voting Classifier**, que combina as previsões dos modelos por meio de votação probabilística (*soft voting*). Todos os modelos foram treinados e avaliados sob as mesmas condições experimentais.

2.5. Métricas de Avaliação

O desempenho dos classificadores foi avaliado no conjunto de teste por meio de métricas adequadas a problemas de classificação e análise de crédito. A **acurácia** representa a proporção de classificações corretas, mas pode ser influenciada pelo desbalanceamento entre as classes. A **precisão** indica a proporção de previsões positivas que foram corretamente classificadas, enquanto o **recall** mede a proporção de casos positivos identificados pelo modelo. O **F1-score** combina precisão e recall em uma única medida, sendo útil quando há interesse no equilíbrio entre essas métricas. A **Área sob a Curva ROC (AUC)** mede a capacidade do modelo de distinguir as classes em diferentes limiares de decisão. O **Índice de Gini**, derivado da AUC, também expressa o poder de discriminação do classificador. Por fim, a **estatística Kolmogorov-Smirnov (KS)** representa a maior separação entre as distribuições acumuladas das duas classes. Como a variável-alvo apresenta desbalanceamento, a análise priorizou conjuntamente o F1-score, a AUC e o KS, não se restringindo à acurácia.

2.6. Curva ROC

A curva ROC (*Receiver Operating Characteristic*) foi utilizada para avaliar o desempenho discriminatório dos modelos em diferentes limiares de decisão. Essa curva relaciona a taxa de verdadeiros positivos (TPR) com a taxa de falsos positivos (FPR), permitindo uma análise visual da performance dos modelos.

2.7. Teste Estatístico de DeLong

Para verificar a significância estatística das diferenças entre as áreas sob a curva ROC, foi aplicado o teste de DeLong. Esse teste permite comparar duas AUCs correlacionadas, avaliando se a diferença observada entre os modelos é estatisticamente significativa.

2.8. Implantação

Planejou-se a integração dos resultados ao fluxo de análise de crédito e as estratégias de monitoramento do modelo em produção [2].

3. Ferramentas Utilizadas

A implementação foi realizada em Python, utilizando o ambiente Google Colaboratory, versão 3.10.12. A biblioteca **NumPy** foi empregada nas operações numéricas e estatísticas [3]; o **Pandas**, na organização, manipulação e análise dos dados [4]; **Matplotlib** e **Seaborn**, na elaboração das visualizações [5, 6]; e o **Scikit-learn**, no pré-processamento, treinamento e avaliação dos modelos de classificação [7].

4. Resultados e Discussão

4.1. Análise Exploratória de Dados

A análise exploratória concentrou-se na caracterização da variável-alvo e na identificação de aspectos relevantes para a avaliação dos classificadores. A Tabela 1 mostra que 71,13% das solicitações foram aprovadas, enquanto 28,87% foram rejeitadas, evidenciando um desbalanceamento entre as classes. Essa característica justifica a utilização conjunta de acurácia, F1-score, AUC e estatística KS, evitando que o desempenho dos modelos seja analisado exclusivamente pela acurácia. Também foram observadas assimetria e presença de valores extremos nas variáveis relacionadas à renda e ao valor do empréstimo. Esses registros foram mantidos por representarem a distribuição observada na base analisada.

Tabela 1. Distribuição da variável-alvo `Loan_Status`.

Classe	Frequência	Proporção (%)
Aprovado (Y)	271	71,13
Rejeitado (N)	110	28,87

4.2. Treinamento dos Modelos

A base processada foi dividida em conjuntos de treinamento e teste, com proporções de 80% e 20%, respectivamente. A divisão foi estratificada pela variável-alvo e realizada com `random_state=16`, resultando em 77 observações no conjunto de teste. Os oito classificadores foram ajustados com os dados de treinamento, etapa em que a otimização de hiperparâmetros foi realizada por *Grid Search*, associada à validação cruzada 10-fold e, em seguida, avaliados no conjunto de teste, que não foi utilizado durante o ajuste dos modelos. As métricas de desempenho e as curvas ROC foram então calculadas para permitir a comparação entre os algoritmos.

4.3. Comparação entre os Modelos

A avaliação foi realizada no conjunto de teste por meio da acurácia, F1-score, AUC, índice de Gini e estatística KS. Os resultados são apresentados na Tabela 2.

Tabela 2. Desempenho dos modelos no conjunto de teste.

Modelo	Acurácia(%)	F1-Score(%)	AUC(%)	Gini(%)	KS(%)
Random Forest	85,7	90,8	82,6	65,3	54,5
Voting	83,1	89,1	80,6	61,2	56,4
Regressão Logística	85,7	90,8	72,7	45,5	54,5
Naive Bayes	85,7	90,8	70,1	40,2	52,7
Árvore de Decisão	75,3	82,9	69,1	38,2	43,6
MLP	68,8	81,0	54,7	9,4	21,8
kNN	68,8	79,7	48,1	-3,7	16,4
SVM	71,4	83,3	44,0	-11,9	25,5

Random Forest, Regressão Logística e Naive Bayes apresentaram os maiores valores de acurácia e F1-score, ambos iguais a 85,7% e aproximadamente 90,8%, respectivamente. Entretanto, a análise da capacidade de discriminação diferenciou esses modelos. O Random Forest obteve a maior AUC (82,6%) e o maior índice de Gini (65,3%), enquanto o Voting apresentou a maior estatística KS (56,4%), ligeiramente superior aos valores obtidos pelo Random Forest e pela Regressão Logística (54,5%).

A Figura 1 apresenta as curvas ROC dos classificadores. O Random Forest exibiu a curva mais próxima do canto superior esquerdo, confirmando sua maior AUC e sua melhor capacidade de ordenar as solicitações aprovadas e rejeitadas. O Voting apresentou o segundo maior valor de AUC (80,6%), seguido pela Regressão Logística (72,7%) e pelo Naive Bayes (70,1%). Os demais modelos apresentaram AUC inferior a 70%, com kNN e SVM ficando abaixo de 50% na configuração avaliada.




Figura 1. Curvas ROC dos modelos de classificação no conjunto de teste.

O teste de DeLong indicou diferença estatisticamente significativa entre o Random Forest e os modelos Árvore de Decisão, kNN, Naive Bayes, MLP e SVM ($p < 0,05$). Entretanto, não foram observadas diferenças significativas entre o Random Forest, a Regressão Logística ($p = 0,100$) e o Voting ($p = 0,112$). Assim, o Random Forest apresentou o melhor desempenho descritivo segundo a AUC e o índice de Gini, mas sua superioridade estatística não foi demonstrada em relação à Regressão Logística e ao Voting.

5. Considerações Finais

Este estudo aplicou a metodologia CRISP-DM à classificação de solicitações de empréstimos, comparando oito modelos de aprendizado de máquina. Random Forest, Regressão Logística e Naive Bayes apresentaram acurácia de 85,7% e F1-score aproximadamente igual a 90,8%. Entretanto, a análise da curva ROC indicou que o Random Forest obteve a maior capacidade discriminatória, com AUC de 82,6% e Gini de 65,3%. O teste de DeLong confirmou diferenças significativas em relação a alguns modelos, mas não em relação à Regressão Logística e ao Voting. Assim, o Random Forest apresentou o melhor desempenho descritivo nesta amostra, sem demonstrar superioridade estatística absoluta.

Tais métricas mostram como o random forest pode ser usado para minimizar falsos positivos na aprovação de crédito, protegendo a instituição financeira de perdas diretas sem penalizar erroneamente bons pagadores em excesso.

Como trabalhos futuros, sugere-se a aplicação de técnicas de balanceamento amostral sintético (como SMOTE) antes da fase de modelagem, além do estudo de explicabilidade do modelo (eXplainable AI, através de metodologias como SHAP) para garantir que as decisões da *Random Forest* obedeçam às regulações de clareza estabelecidas em algoritmos financeiros.

Referências

- [1] Harine Matos Maciel and Wlisses Matos Maciel. Análise da inadimplência em uma instituição financeira na região metropolitana de fortaleza. *Essentia-Revista de Cultura, Ciência e Tecnologia da UVA*, 16(2), 2015.
- [2] Pete Chapman, Julian Clinton, Randy Kerber, Thomas Khabaza, Thomas Reinartz, Colin Shearer, and Ruediger Wirth. *Crisp-dm 1.0: Step-by-step data mining guide*. SPSS inc, 2000.
- [3] Charles R. Harris, K. Jarrod Millman, St'efan J. van der Walt, Ralf Gommers, Pauli Virtanen, David Cournapeau, Eric Wieser, Julian Taylor, Sebastian Berg, Nathaniel J. Smith, Robert Kern, Matti Picus, Stephan Hoyer, Marten H. van Kerkwijk, Matthew Brett, Allan Haldane, Jaime Fern'andez del R'io, Mark Wiebe, Pearu Peterson, Pierre G'erard-Marchant, Kevin Sheppard, Tyler Reddy, Warren Weckesser, Hameer Abbasi, Christoph Gohlke, and Travis E. Oliphant. Array programming with NumPy. *Nature*, 585(7825):357–362, September 2020.
- [4] The pandas development team. pandas-dev/pandas: Pandas, February 2020.
- [5] J. D. Hunter. Matplotlib: A 2d graphics environment. *Computing in Science & Engineering*, 9(3):90–95, 2007.
- [6] Michael L. Waskom. seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60):3021, 2021.
- [7] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.