

Modelos Preditivos para Estimação de Status de Empréstimos via Machine Learning: Uma Abordagem Baseada na Metodologia CRISP-DM

Mário Diego Rocha Valente¹, Gabriel Baia da Silva¹, Jefferson Magalhães de Moraes¹

¹Instituto de Ciências Exatas e Naturais (ICEN) - Universidade Federal do Pará (UFPA)
Rua Augusto Corrêa 01 – Guamá – Belém – PA – Brasil

diego.valente@gmail.com, gabrielkadran@hotmail.com, jmorais@ufpa.br

Resumo. O objetivo deste trabalho foi aplicar modelos preditivos de aprendizado de máquina para classificação de status de empréstimo, estruturada sob a metodologia CRISP-DM. O conjunto de dados, obtido do Kaggle, contém informações de empréstimos imobiliários. O dataset foi utilizado para realizar a comparação entre modelos de aprendizado de máquina e determinar dentre estes qual o mais adequado para a decisão sobre a liberação de crédito imobiliário. A amostra foi dividida em dados de treino (80%) e teste (20%), com aplicação de padronização escalar rigorosa (Z-score) e otimização de hiperparâmetros, que foi realizada por Grid Search, associada à validação cruzada 10-fold. Nesta comparação, por meio da Curva ROC, o Random Forest foi identificado como o modelo mais adequado para a aplicação, atingindo uma AUC de 82,6%, contra 80,6% do Voting e 72,7% da Regressão Logística.

Abstract. The objective of this study was to apply predictive machine learning models for loan status classification, structured under the CRISP-DM methodology. The dataset, obtained from Kaggle, contains information on real estate loans. It was used to compare machine learning models and determine the most suitable one for decision-making regarding real estate credit approval. The sample was split into training (80%) and testing (20%) sets, followed by the application of rigorous standard scaling (Z-score) and hyperparameter optimization, which was performed by Grid Search associated with 10-fold cross-validation. Through this comparison using the ROC Curve, Random Forest was identified as the most appropriate model for this application, achieving an AUC of 82.6%, compared to 80.6% for the Voting classifier and 72.7% for Logistic Regression.

1. Introdução

A análise de solicitações de crédito imobiliário envolve decisões que devem considerar simultaneamente eficiência operacional e capacidade de discriminação entre solicitações aprovadas e rejeitadas. Nesse contexto, modelos preditivos podem apoiar a triagem de propostas e contribuir para decisões mais consistentes a partir das características cadastrais, financeiras e imobiliárias dos solicitantes [1].

Estudos recentes de *credit scoring* têm demonstrado a eficácia de algoritmos de *Machine Learning* quando comparados a métodos estatísticos tradicionais, apresentando maior robustez em dados complexos [2, 3], além de impulsionarem a necessidade de modelos explicáveis (*Explainable AI*) altamente precisos aplicados a plataformas financeiras

digitais [4, 5]. Este trabalho busca contribuir com essa literatura ao avaliar o desempenho de diferentes métodos de aprendizado de máquina no suporte à decisão de crédito, verificando se a superioridade de modelos complexos se reflete de maneira estatisticamente significativa.

Este estudo utiliza o conjunto de dados `loan_data.csv`, obtido no **Kaggle**, referente a dados de clientes de empréstimo bancário. A variável binária `Loan_Status`, correspondente ao status de aprovação do empréstimo sendo 0 reprovado ou 1 aprovado, é o nosso alvo (*target*) de análise. O desenvolvimento foi estruturado segundo a metodologia *Cross Industry Standard Process for Data Mining* (CRISP-DM) [6].

2. Materiais e Métodos

O desenvolvimento deste estudo seguiu as seis etapas do framework CRISP-DM: Entendimento do Negócio, Entendimento dos Dados, Preparação dos Dados, Modelagem, Avaliação e Implantação [6].

2.1. Entendimento do Negócio

Nesta fase, buscou-se alinhar os objetivos técnicos com as necessidades financeiras. O foco é automatizar a triagem de crédito imobiliário para reduzir a inadimplência e aumentar a eficiência operacional da instituição financeira.

2.2. Entendimento dos Dados

O conjunto de dados `loan_data.csv`, obtido no Kaggle, possui 381 registros e 13 colunas. As variáveis descrevem características sociodemográficas e, em especial, informações financeiras críticas para a análise: `ApplicantIncome` (renda do solicitante principal), `CoapplicantIncome` (renda do co-solicitante), `LoanAmount` (valor total do empréstimo solicitado) e `Loan_Amount_Term` (prazo concedido para o pagamento do empréstimo em meses). A coluna `Loan_ID` não foi utilizada como preditor, e a variável-alvo `Loan_Status` indica aprovação (Y) ou rejeição (N).

2.3. Preparação dos Dados

A preparação da base incluiu a verificação de valores ausentes, preenchidos pelas modas em variáveis categóricas e pelas medianas nas numéricas temporais. As variáveis categóricas foram transformadas numericamente por *Label Encoding* (Y=1, N=0). Em seguida, a matriz foi separada para treinamento e avaliação.

2.4. Modelagem

Foram avaliados oito métodos de classificação: **Regressão Logística** (*baseline*), **Árvore de Decisão**, **k-Nearest Neighbors (kNN)**, **Naive Bayes Gaussiano**, **Support Vector Machine (SVM)**, **Multilayer Perceptron (MLP)**, **Random Forest** e **Voting Classifier** (*soft voting*). Todos foram treinados e avaliados sob as mesmas condições experimentais.

2.5. Avaliação e Implantação

O desempenho no conjunto de teste foi mensurado por métricas consagradas na avaliação de classificadores [7]: **acurácia**; **F1-score**, métrica essencial dado o desbalanceamento das classes; **Área sob a Curva ROC (AUC)**, que relaciona a taxa de verdadeiros e falsos positivos em diferentes limiares; **Índice de Gini**, derivado da AUC; e **estatística Kolmogorov-Smirnov (KS)**.

Para verificar a significância estatística das diferenças entre as áreas sob a curva ROC, aplicou-se o teste não paramétrico de DeLong [8]. Por fim, a fase de implantação planejou a integração dos modelos e estratégias de monitoramento no fluxo real de análise [6].

3. Ferramentas Utilizadas

A implementação foi realizada em Python no Google Colaboratory. Bibliotecas como NumPy, Pandas, Matplotlib, Seaborn e Scikit-learn foram empregadas. Os códigos, apresentações e *scripts* reprodutíveis estão publicamente disponíveis no GitHub¹ e no Google Colab².

4. Resultados e Discussão

4.1. Análise Exploratória de Dados

A fim de compreender as características intrínsecas da base, estatísticas descritivas foram extraídas. A Tabela 1 apresenta um resumo dos atributos numéricos (em sua escala original para facilitar a interpretação).

Tabela 1. Estatísticas dos Atributos Numéricos.

Variável	Média	Desv. Pad.	Min	Max
Renda do Candidato	\$ 3.579,85	\$ 1.419,81	\$ 150,00	\$ 9.703,00
Renda do Fiador	\$ 1.277,28	\$ 2.340,82	\$ 0,00	\$ 33.837,00
Valor Empréstimo (milhares)	\$ 104.986	\$ 28.358	\$ 9.000,00	\$ 150.000,00
Prazo do Empréstimo (meses)	341	68	12	480

Tabela 2. Distribuição dos Atributos Categóricos.

Atributo	Moda	Frequência	Relativa (%)
Gênero	Masculino	296	77,69
Estado Civil	Casado	228	59,84
Nº de Dependentes	1	242	63,52
Escolaridade	Graduação	278	72,97
Trabalhador Autônomo	Não	346	90,81
Histórico de Crédito	Sim	324	85,04
Área de Residência	Semiurbana	149	39,11
Status de Empréstimo	Aprovado	271	71,13

¹https://github.com/MarioDhiego/Slide_ERIN_2026

²<https://colab.research.google.com/drive/1bM0SFVu0IQhGwztCZHo2HhptDlSos2jZ?usp=sharing>

Além disso, a Tabela 2 consolida as características sociodemográficas e o histórico de crédito, evidenciando o perfil majoritário dos clientes.

Nota-se que 71,13% das solicitações foram aprovadas (variável-alvo). Esse desbalanceamento justifica o uso de F1-score, AUC e KS em vez da análise puramente baseada na acurácia. Cabe ressaltar que a base possui apenas 381 registros totais. Conforme apontado por Vabalas *et al.* [9], conjuntos de dados com amostras limitadas impõem restrições severas à validação de algoritmos de *Machine Learning*, podendo superestimar o desempenho e limitar a capacidade de generalização irrestrita dos resultados.

4.2. Treinamento e Comparação entre os Modelos

Com 80% de dados de treino e otimização por *Grid Search* via *cross-validation* (10-fold), os modelos foram aplicados aos 20% restantes (teste). A Tabela 3 expõe os resultados com os melhores valores destacados em negrito.

Tabela 3. Avaliação dos modelos no conjunto de teste.

Modelo	Acurácia (%)	F1-Score (%)	AUC (%)	Gini (%)	KS (%)
Random Forest	85,7	90,8	82,6	65,3	54,5
Voting	83,1	89,1	80,6	61,2	56,4
Regressão Logística	85,7	90,8	72,7	45,5	54,5
Naive Bayes	85,7	90,8	70,1	40,2	52,7
Árvore de Decisão	75,3	82,9	69,1	38,2	43,6
MLP	68,8	81,0	54,7	9,4	21,8
kNN	68,8	79,7	48,1	-3,7	16,4
SVM	71,4	83,3	44,0	-11,9	25,5

Nota: Random Forest obteve o maior poder discriminatório isolado (AUC e Gini).

Random Forest, Regressão Logística e Naive Bayes lideraram em acurácia (85,7%). Contudo, o Random Forest destacou-se na discriminação com a maior AUC (82,6%). A Figura 1 ilustra o Random Forest mais próximo ao canto superior esquerdo.

O teste de DeLong foi aplicado para verificar a significância estatística das diferenças observadas entre as AUCs. Conforme ilustra a Tabela 4, o Random Forest apresentou superioridade significativa frente à maioria dos classificadores ($p < 0,05$), contudo, não houve diferença estatisticamente significativa em relação ao modelo Voting e à Regressão Logística.

Tabela 4. Teste de DeLong: Comparação com o Random Forest (Baseline).

Modelo Avaliado	Valor-p	Dif. Significativa ($\alpha = 0,05$)
Voting	0,112310	Não
Regressão Logística	0,100014	Não
Naive Bayes	< 0,006914	Sim
Árvore de Decisão	< 0,018508	Sim
MLP	< 0,000410	Sim
SVM	< 0,000718	Sim
kNN	< 0,000041	Sim




Figura 1. Curvas ROC dos modelos de classificação no conjunto de teste.

4.3. Análise do Modelo Definitivo (Random Forest)

Para alinhar os resultados às necessidades de negócio, analisou-se a matriz de confusão gerada pelo Random Forest nas 77 instâncias de teste. O algoritmo identificou corretamente 54 verdadeiros positivos e 12 verdadeiros negativos. Houve 10 falsos positivos (risco de calote sob controle) e apenas 1 falso negativo (rejeição equivocada), atingindo um *recall* de 98,1% na classe majoritária, garantindo que bons clientes não sejam afugentados pela instituição financeira. No contexto de crédito, o índice de Gini superior a 60% (65,3%) e o KS superior a 50% (54,5%) consolidam uma segmentação altamente eficaz entre bons e maus pagadores.




Figura 2. Importância das variáveis preditoras no modelo Random Forest.

Ademais, visando a explicabilidade do modelo, a Figura 2 ilustra a contribuição individual de cada variável. O `Credit_History` demonstrou ser, de longe, o preditor mais decisivo para a concessão de crédito, seguido por características estritamente financeiras como a renda do solicitante (`ApplicantIncome`), o valor do empréstimo (`LoanAmount`) e a renda do fiador (`CoapplicantIncome`).

5. Considerações Finais

Este estudo aplicou o CRISP-DM à aprovação de crédito. Embora o Random Forest tenha alcançado a maior AUC (82,6%), o teste de DeLong revelou que sua superioridade frente à Regressão Logística e ao Voting não é estatisticamente significativa. Aliado ao tamanho restrito da base de dados (381 registros), essa descoberta exige cautela institucional: adotar um modelo mais complexo pode não trazer um impacto financeiro superior em comparação a modelos lineares mais simples e explicáveis neste escopo específico. Como trabalhos futuros, sugere-se a aplicação em bases maiores, técnicas de balanceamento (SMOTE) e explicabilidade avançada por meio de metodologias como SHAP para apoiar o processo de decisão e a transparência em ferramentas de crédito, o que corrobora achados recentes da literatura [5].

Referências

- [1] Harine Matos Maciel and Wlisses Matos Maciel. Análise da inadimplência em uma instituição financeira na região metropolitana de fortaleza. *Essentia-Revista de Cultura, Ciência e Tecnologia da UVA*, 16(2), 2015.
- [2] Stefan Lessmann, Bart Baesens, Hsin-Vonn Seow, and Lyn C Thomas. Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research. *European Journal of Operational Research*, 247(1):124–136, 2015.
- [3] Iain Brown and Christophe Mues. Experimental comparison of classification algorithms for credit scoring. *Expert Systems with Applications*, 39(4):3446–3453, 2012.
- [4] N. Bussmann, P. Giudici, D. Marinelli, and J. Papenbrock. Explainable machine learning in credit risk management. *Computational Economics*, 57(1):203–216, 2021.
- [5] A. Pamisetty, S. Paleti, B. Adusupalli, J. Singireddy, R. Inala, and K. C. Nagabhyru. Explainable ai systems for credit scoring and loan risk assessment in digital banking platforms. In *2025 IEEE 13th International Conference on Intelligent Data Acquisition and Advanced Computing Systems: Technology and Applications (IDAACS)*, pages 1478–1483. IEEE, 2025.
- [6] Pete Chapman, Julian Clinton, Randy Kerber, Thomas Khabaza, Thomas Reinartz, Colin Shearer, and Ruediger Wirth. *Crisp-dm 1.0: Step-by-step data mining guide*. SPSS inc, 2000.
- [7] Marina Sokolova and Guy Lapalme. A systematic analysis of performance measures for classification tasks. *Information processing & management*, 45(4):427–437, 2009.
- [8] Elizabeth R DeLong, David M DeLong, and Daniel L Clarke-Pearson. Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*, 44(3):837–845, 1988.
- [9] Andrius Vabalas, Emma Gowen, Ellen Poliakoff, and Alexander J Casson. Machine learning algorithm validation with a limited sample size. *PloS one*, 14(11):e0224365, 2019.