



Modelos Preditivos para Estimação de Status de Empréstimos Bancários via Machine Learning: Uma Abordagem Baseada na Metodologia CRISP-DM

Mário Diego Valente¹ Gabriel Baia da Silva¹ Jefferson Magalhães de Moraes²

¹Graduando em Sistemas de Informação - UFPA

²Professor Dr., Faculdade de Computação - UFPA

Introdução e Objetivos

Contexto

- A análise de solicitações de crédito imobiliário exige equilíbrio entre **eficiência operacional** e **capacidade de discriminação**.
- Modelos preditivos auxiliam na triagem de propostas utilizando características cadastrais, financeiras e imobiliárias.

Objetivo do Trabalho

- Aplicar modelos preditivos de *Machine Learning* para classificação do status de aprovação de empréstimos.
- Comparar oito classificadores e identificar o mais adequado utilizando a metodologia **CRISP-DM**.

Metodologia: Dados e Preparação

Entendimento dos Dados

- **Dataset:** `loan_data.csv` (Kaggle).
- **Tamanho:** 381 registros e 13 variáveis.
- **Variável-alvo:** `Loan_Status` (0 = Reprovado; 1 = Aprovado).

Preparação da Base

- Tratamento de valores ausentes (moda para categóricas e mediana para numéricas).
- Transformação por *Label Encoding*.
- **Divisão da Amostra:** 80% Treino e 20% Teste.
- Aplicação de padronização escalar rigorosa (Z-score).

Metodologia: Ferramentas Utilizadas

Para conduzir as análises e estimativas neste estudo, foi adotada a linguagem de programação **Python**, utilizando a **IDE Google Colaboratory** na versão 3.10.12. Foram empregadas as seguintes bibliotecas para implementação das diversas etapas do processo:

- NumPy [OLIPHANT, T. E. et al. (2006)]
- Pandas [MCKINNEY, W. (2010)]
- Matplotlib [HUNTER, J. D. (2007)]
- Seaborn [WASKOM, M. (2021)]
- Scikit-learn [PEDREGOSA, F. et al. (2011)]

Modelos Avaliados (8 classificadores)

- Regressão Logística (*baseline*)
- Árvore de Decisão e Random Forest
- k-Nearest Neighbors (kNN)
- Naive Bayes Gaussiano (NBG)
- Support Vector Machine (SVM)
- Multilayer Perceptron (MLP)
- Voting Classifier (*soft voting*)

Otimização e Validação

- *Grid Search* associado à **Validação Cruzada 10-fold**.
- Métricas: Acurácia, F1-Score, AUC, Gini e KS.

Resultados: Análise Exploratória de Dados (1/2)

A fim de compreender as características intrínsecas da base, estatísticas descritivas foram extraídas. A Tabela 1 apresenta um resumo dos atributos numéricos (em sua escala original para facilitar a interpretação).

Tabela: Estatísticas dos atributos numéricos.

Variável	Média	Desv. Pad.	Min	Max
Renda do Candidato	\$ 3.579,85	\$ 1.419,81	\$ 150,00	\$ 9.703,00
Renda do Fiador	\$ 1.277,28	\$ 2.340,82	\$ 0,00	\$ 33.837,00
Valor Empréstimo (milhares)	\$ 104.986	\$ 28.358	\$ 9.000,00	150.000,00
Prazo do Empréstimo (meses)	341	68	12	480

Resultados: Análise Exploratória de Dados (2/2)

Tabela: Distribuição dos Atributos Categóricos.

Atributo	Moda	Frequência	Relativa (%)
Gênero	Masculino	296	77,69
Estado Civil	Casado	228	59,84
Nº de Dependentes	0	242	63,52
Escolaridade	Graduação	278	72,97
Trabalhador Autônomo	Não	346	90,81
Histórico de Crédito	Sim	324	85,04
Area de Residência	Semiurbana	149	39,11
Estatus de Empréstimo	Aprovado	271	71,13

Resultados: Desempenho Geral dos Modelos


Tabela: Avaliação dos modelos no conjunto de teste.

Modelo	Acurácia (%)	F1-Score (%)	AUC (%)	Gini (%)	KS (%)
Random Forest	85,7	90,8	82,6	65,3	54,5
Voting	83,1	89,1	80,6	61,2	56,4
Regressão Logística	85,7	90,8	72,7	45,5	54,5
Naive Bayes	85,7	90,8	70,1	40,2	52,7
Árvore de Decisão	75,3	82,9	69,1	38,2	43,6
MLP	68,8	81,0	54,7	9,4	21,8
kNN	68,8	79,7	48,1	-3,7	16,4
SVM	71,4	83,3	44,0	-11,9	25,5

Nota: Random Forest obteve o maior poder discriminatório isolado (AUC e Gini).

Resultados: Análise da Curva ROC

- A Curva ROC atesta visualmente a robustez dos classificadores.
- **Random Forest** apresentou a curva mais deslocada para o canto superior esquerdo (AUC 82,6%).
- Fica evidente a superioridade sobre a *baseline* (Regressão Logística).



Resultados: Teste Estatístico de DeLong

- O **Teste de DeLong** foi aplicado para verificar a **significância estatística** das diferenças empíricas entre as áreas sob a curva (AUC).
- **Random Forest (Baseline)**: Possui diferença significativa em relação à maioria dos modelos, **exceto** para Regressão Logística e Voting Classifier.

Tabela: Comparação com o modelo de melhor desempenho (Random Forest)

Modelo Avaliado	Valor-p	Dif. Significativa ($\alpha = 0,05$)
Voting	0,112310	Não
Regressão Logística	0,100014	Não
Naive Bayes	< 0,006914	Sim
Árvore de Decisão	< 0,018508	Sim
MLP	< 0,000410	Sim
SVM	< 0,000718	Sim
kNN	< 0,000041	Sim

Resultados: O Modelo Definitivo (Random Forest)

Matriz de Confusão (77 instâncias)

- **Verdadeiros Positivos (54):** Bons pagadores aprovados corretamente.
- **Verdadeiros Negativos (12):** Maus pagadores identificados e negados.
- **Falsos Negativos (1):** Apenas um bom cliente negado (praticamente não há perda de bons negócios).
- **Falsos Positivos (10):** Risco de calote sob rígido controle.

Métricas de Risco e Negócio

- **Recall (98,1%):** Praticamente perfeito. Garante que os clientes lucrativos não sejam afugentados pela instituição.
- **Gini (65,3%):** No mercado financeiro, valores superiores a 60% indicam um modelo fortíssimo e lucrativo.
- **KS (54,5%):** Separação formidável. A distância entre bons e maus clientes ultrapassa 50%, provando uma segmentação altamente eficaz.

Considerações Finais e Trabalhos Futuros

Conclusões

- O **Random Forest** apresentou o melhor desempenho descritivo e a maior capacidade discriminatória global no cenário estudado.
- O modelo demonstrou-se apto para **minimizar falsos positivos**, protegendo a instituição de perdas diretas sem penalizar erroneamente bons pagadores.

Trabalhos Futuros

- Aplicação de técnicas de balanceamento amostral sintético prévio (Ex: SMOTE).
- Estudo de explicabilidade do modelo (*eXplainable AI* via SHAP) para adequação às exigências e regulações financeiras de transparência.

Obrigado!

Contatos:

diego.vatente@gmail.com

gabrielkadran@hotmail.com

jmoraes@ufpa.br